

Aula 18 - Algoritmos de Agrupamento

João Florindo

Instituto de Matemática, Estatística e Computação Científica
Universidade Estadual de Campinas - Brasil
florindo@unicamp.br

Outline



- 1 Introdução
- 2 Agrupamento (*Clustering*)
- 3 Inicialização e Número de Clusters

- Antes:

$$\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), (x^{(3)}, y^{(3)}), \dots, (x^{(m)}, y^{(m)})\}.$$

- Agora:

$$\{x^{(1)}, x^{(2)}, x^{(3)}, \dots, x^{(m)}\}.$$



Aplicações

- Segmentação de mercado
- Redes sociais
- Clusters de computadores
- Astronomia

Aplicações

- Segmentação de mercado
- Redes sociais
- Clusters de computadores
- Astronomia

Aplicações

- Segmentação de mercado
- Redes sociais
- Clusters de computadores
- Astronomia

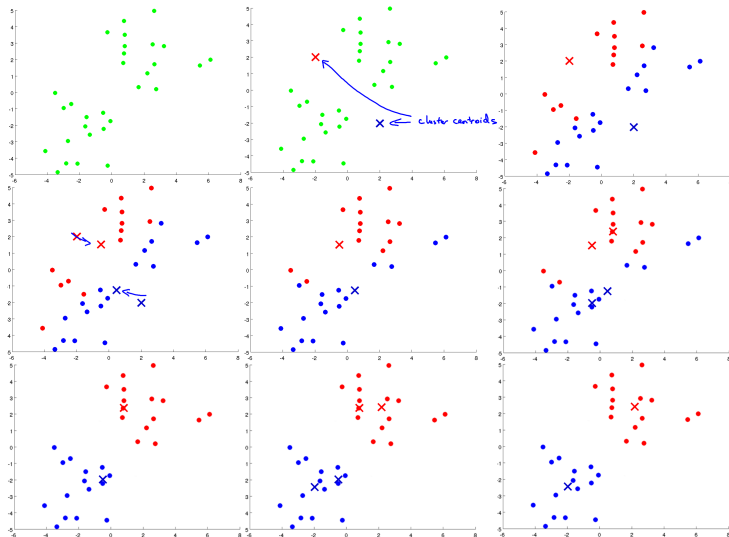
Aplicações

- Segmentação de mercado
- Redes sociais
- Clusters de computadores
- Astronomia



Outline

- 1 Introdução
- 2 Agrupamento (*Clustering*)
- 3 Inicialização e Número de Clusters

K-means



K-means



Função Objetivo

Notação

- $c^{(i)}$: índice do cluster $(1, 2, \dots, K)$ ao qual o exemplo $x^{(i)}$ está atribuído
- μ_k : centroide k ($\mu_k \in \mathbb{R}^n$)
- $\mu_{c^{(i)}}$: centroide do cluster ao qual o exemplo $x^{(i)}$ foi atribuído

Função objetivo:

$$J(c^{(1)}, \dots, c^{(m)}, \mu_1, \dots, \mu_K) = \frac{1}{m} \sum_{i=1}^m \|x^{(i)} - \mu_{c^{(i)}}\|^2$$

Otimização:

$$\underset{\substack{c^{(1)}, \dots, c^{(m)} \\ \mu_1, \dots, \mu_K}}{\operatorname{argmin}} J(c^{(1)}, \dots, c^{(m)}, \mu_1, \dots, \mu_K).$$

A função J é chamada de **distorção**.

Função Objetivo

- O algoritmo é de coordenada descendente sobre J .
- o primeiro laço do algoritmo (atribuição do cluster) minimiza J w.r.t. $c^{(1)}, \dots, c^{(m)}$, mantendo-se μ_1, \dots, μ_K fixos.
- Já o segundo laço (movimento do centroide) minimiza J w.r.t. μ_1, \dots, μ_K .
- J é não-convexa (sem garantia de convergência para mínimo global).

Função Objetivo

- O algoritmo é de coordenada descendente sobre J .
- o primeiro laço do algoritmo (atribuição do cluster) minimiza J w.r.t. $c^{(1)}, \dots, c^{(m)}$, mantendo-se μ_1, \dots, μ_K fixos.
- Já o segundo laço (movimento do centroide) minimiza J w.r.t. μ_1, \dots, μ_K .
- J é não-convexa (sem garantia de convergência para mínimo global).

Função Objetivo

- O algoritmo é de coordenada descendente sobre J .
- o primeiro laço do algoritmo (atribuição do cluster) minimiza J w.r.t. $c^{(1)}, \dots, c^{(m)}$, mantendo-se μ_1, \dots, μ_K fixos.
- Já o segundo laço (movimento do centroide) minimiza J w.r.t. μ_1, \dots, μ_K .
- J é não-convexa (sem garantia de convergência para mínimo global).

Função Objetivo

- O algoritmo é de coordenada descendente sobre J .
- o primeiro laço do algoritmo (atribuição do cluster) minimiza J w.r.t. $c^{(1)}, \dots, c^{(m)}$, mantendo-se μ_1, \dots, μ_K fixos.
- Já o segundo laço (movimento do centroide) minimiza J w.r.t. μ_1, \dots, μ_K .
- J é não-convexa (sem garantia de convergência para mínimo global).

Outline

- 1 Introdução
- 2 Agrupamento (*Clustering*)
- 3 Inicialização e Número de Clusters


Inicialização

- Selecionar K exemplos de treinamento aleatoriamente e usar como μ_1, \dots, μ_K .
- Diferentes inicializações geram diferentes agrupamentos (mínimos locais de J).



Inicialização

- Selecionar K exemplos de treinamento aleatoriamente e usar como μ_1, \dots, μ_K .
- Diferentes inicializações geram diferentes agrupamentos (mínimos locais de J).



Inicialização

- Rodar o algoritmo várias vezes e tomar o caso com menor custo.

Para $i = 1$ até 100{

 Inicializar o K-means aleatoriamente.

 Rodar o K-means e obter $c^{(1)}, \dots, c^{(m)}, \mu_1, \dots, \mu_K$.

 Calcular a função de custo (distorção)

$$J(c^{(1)}, \dots, c^{(m)}, \mu_1, \dots, \mu_K)$$

}

Tome o agrupamento com menor custo $J(c^{(1)}, \dots, c^{(m)}, \mu_1, \dots, \mu_K)$

- Interessante sobretudo quando K é pequeno (2 a 5, por exemplo), não é necessário para K muito grande.

Inicialização

- Rodar o algoritmo várias vezes e tomar o caso com menor custo.

Para $i = 1$ até 100{

 Inicializar o K-means aleatoriamente.

 Rodar o K-means e obter $c^{(1)}, \dots, c^{(m)}, \mu_1, \dots, \mu_K$.

 Calcular a função de custo (distorção)

$$J(c^{(1)}, \dots, c^{(m)}, \mu_1, \dots, \mu_K)$$



}

Tome o agrupamento com menor custo $J(c^{(1)}, \dots, c^{(m)}, \mu_1, \dots, \mu_K)$

- Interessante sobretudo quando K é pequeno (2 a 5, por exemplo), não é necessário para K muito grande.

Números de Clusters



- Qual o valor ideal de K ?
- Método do “cotovelo” (“*elbow*”).
- Plotar J em função do número de clusters e identificar o ponto a partir do qual J decresce muito mais lentamente (“cotovelo”).



- PROBLEMA: decaimento pode ser homogêneo (sem “cotovelo”)!

Números de Clusters



- Qual o valor ideal de K ?
- Método do “cotovelo” (“*elbow*”).
- Plotar J em função do número de clusters e identificar o ponto a partir do qual J decresce muito mais lentamente (“cotovelo”).



- PROBLEMA: decaimento pode ser homogêneo (sem “cotovelo”)!

Números de Clusters



- Qual o valor ideal de K ?
- Método do “cotovelo” (“*elbow*”).
- Plotar J em função do número de clusters e identificar o ponto a partir do qual J decresce muito mais lentamente (“cotovelo”).



- PROBLEMA: decaimento pode ser homogêneo (sem “cotovelo”)!

Números de Clusters

- Qual o valor ideal de K ?
- Método do “cotovelo” (“*elbow*”).
- Plotar J em função do número de clusters e identificar o ponto a partir do qual J decresce muito mais lentamente (“cotovelo”).



- PROBLEMA: decaimento pode ser homogêneo (sem “cotovelo”)!

Números de Clusters

- Se houver uma métrica do contexto do problema que depende de K , é sempre importante levar em conta.
- NOTA: quando nenhum exemplo é atribuído a determinado centroide, o mais comum é eliminar aquele cluster.
- Outra solução, mas menos usual, é rodar novamente com outra inicialização aleatória.

Números de Clusters

- Se houver uma métrica do contexto do problema que depende de K , é sempre importante levar em conta.
- NOTA: quando nenhum exemplo é atribuído a determinado centroide, o mais comum é eliminar aquele cluster.
- Outra solução, mas menos usual, é rodar novamente com outra inicialização aleatória.

Números de Clusters

- Se houver uma métrica do contexto do problema que depende de K , é sempre importante levar em conta.
- NOTA: quando nenhum exemplo é atribuído a determinado centroide, o mais comum é eliminar aquele cluster.
- Outra solução, mas menos usual, é rodar novamente com outra inicialização aleatória.