

Aula 25 - Redes Convolucionais (Parte II)

João Florindo

Instituto de Matemática, Estatística e Computação Científica
Universidade Estadual de Campinas - Brasil
florindo@unicamp.br

Outline

1 Na Prática

2 Histórico

3 Futuro

Tarefas

- **Classificação:** atribuir categorias de objetos a uma imagem.
- **Localização:** moldura em torno do objeto alvo.
- **Detecção:** localização de múltiplos objetos (múltiplos *bounding boxes* e rótulos).
- **Segmentação:** Contorno e rótulo do objeto de interesse.

Tarefas

- **Classificação:** atribuir categorias de objetos a uma imagem.
- **Localização:** moldura em torno do objeto alvo.
- **Detecção:** localização de múltiplos objetos (múltiplos *bounding boxes* e rótulos).
- **Segmentação:** Contorno e rótulo do objeto de interesse.

Tarefas

- **Classificação:** atribuir categorias de objetos a uma imagem.
- **Localização:** moldura em torno do objeto alvo.
- **Detecção:** localização de múltiplos objetos (múltiplos *bounding boxes* e rótulos).
- **Segmentação:** Contorno e rótulo do objeto de interesse.

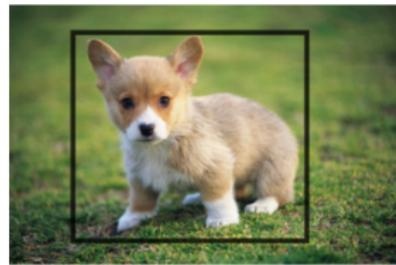
Tarefas

- **Classificação:** atribuir categorias de objetos a uma imagem.
- **Localização:** moldura em torno do objeto alvo.
- **Detecção:** localização de múltiplos objetos (múltiplos *bounding boxes* e rótulos).
- **Segmentação:** Contorno e rótulo do objeto de interesse.

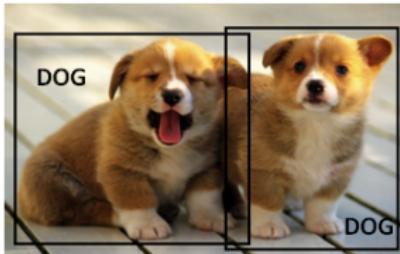
Tarefas



Object Classification is the task of identifying that picture is a dog



Object Localization involves the class label as well as a bounding box to show where the object is located.



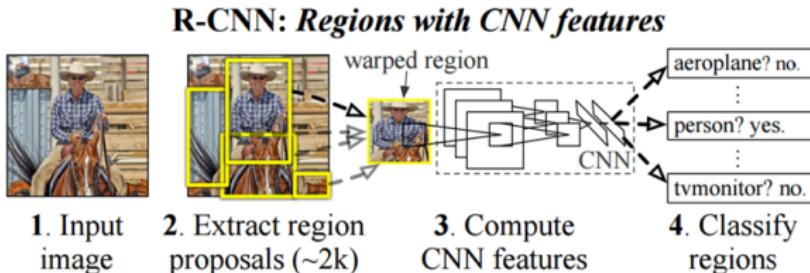
Object Detection involves localization of multiple objects (doesn't have to be the same class).



Object Segmentation involves the class label as well as an outline of the object in interest.

Outras abordagens - R-CNN

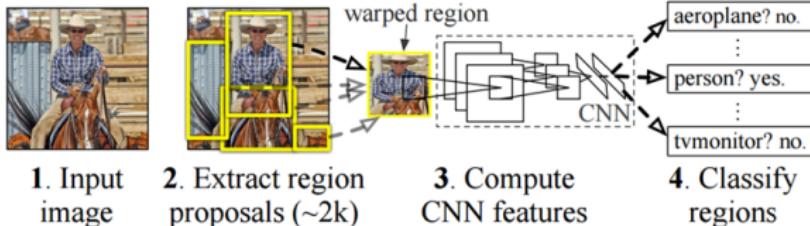
- CNNs baseadas em regiões - Ross Girshick (UC Berkeley).
- Detecção de objetos (retângulo em volta do objeto de interesse)
- Busca seletiva: Define regiões potenciais (da ordem de milhares) por similaridade.
- Imagem de cada região submetida a uma CNN e classificada como pertencente ou não ao objeto de interesse.



Outras abordagens - R-CNN

- CNNs baseadas em regiões - Ross Girshick (UC Berkeley).
- Detecção de objetos (retângulo em volta do objeto de interesse)
- Busca seletiva: Define regiões potenciais (da ordem de milhares) por similaridade.
- Imagem de cada região submetida a uma CNN e classificada como pertencente ou não ao objeto de interesse.

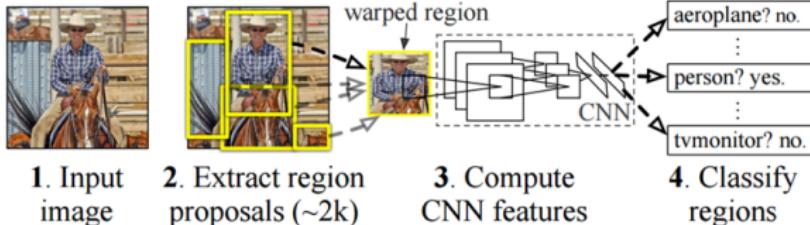
R-CNN: *Regions with CNN features*



Outras abordagens - R-CNN

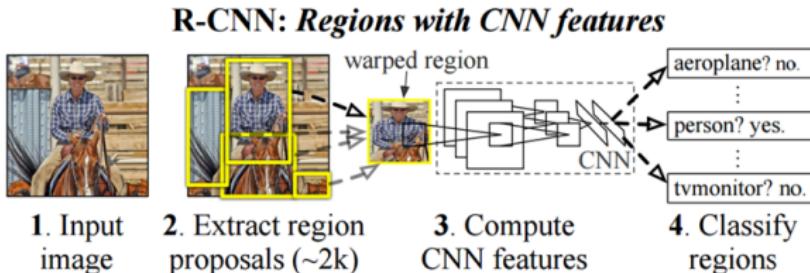
- CNNs baseadas em regiões - Ross Girshick (UC Berkeley).
- Detecção de objetos (retângulo em volta do objeto de interesse)
- Busca seletiva: Define regiões potenciais (da ordem de milhares) por similaridade.
- Imagem de cada região submetida a uma CNN e classificada como pertencente ou não ao objeto de interesse.

R-CNN: *Regions with CNN features*



Outras abordagens - R-CNN

- CNNs baseadas em regiões - Ross Girshick (UC Berkeley).
- Detecção de objetos (retângulo em volta do objeto de interesse)
- Busca seletiva: Define regiões potenciais (da ordem de milhares) por similaridade.
- Imagem de cada região submetida a uma CNN e classificada como pertencente ou não ao objeto de interesse.



Transfer Learning

- Modelo pré-treinado (pesos e parâmetros) em uma rede grande (normalmente pública) e finamente ajustada para a aplicação específica.
- Parte pré-treinada age como extrator de características da imagem.
- Última camada da rede pré-treinada é removida e substituída pelo seu próprio classificador.
- Pesos da rede pré-treinada são congelados (não se alteram durante o *backpropagation*).

Transfer Learning

- Modelo pré-treinado (pesos e parâmetros) em uma rede grande (normalmente pública) e finamente ajustada para a aplicação específica.
- Parte pré-treinada age como extrator de características da imagem.
- Última camada da rede pré-treinada é removida e substituída pelo seu próprio classificador.
- Pesos da rede pré-treinada são congelados (não se alteram durante o *backpropagation*).

Transfer Learning

- Modelo pré-treinado (pesos e parâmetros) em uma rede grande (normalmente pública) e finamente ajustada para a aplicação específica.
- Parte pré-treinada age como extrator de características da imagem.
- Última camada da rede pré-treinada é removida e substituída pelo seu próprio classificador.
- Pesos da rede pré-treinada são congelados (não se alteram durante o *backpropagation*).

Transfer Learning

- Modelo pré-treinado (pesos e parâmetros) em uma rede grande (normalmente pública) e finamente ajustada para a aplicação específica.
- Parte pré-treinada age como extrator de características da imagem.
- Última camada da rede pré-treinada é removida e substituída pelo seu próprio classificador.
- Pesos da rede pré-treinada são congelados (não se alteram durante o *backpropagation*).

Transfer Learning

- Rede mais usada é a ImageNet: 14 milhões de imagens e mais de mil classes.
- Camadas iniciais detectam padrões de baixo nível (como curvas e bordas), que são universais.
- Se a base analisada é muito diferente da ImageNet pode-se usar menos camadas pré-treinadas e mais para o problema específico.

Transfer Learning

- Rede mais usada é a ImageNet: 14 milhões de imagens e mais de mil classes.
- Camadas iniciais detectam padrões de baixo nível (como curvas e bordas), que são universais.
- Se a base analisada é muito diferente da ImageNet pode-se usar menos camadas pré-treinadas e mais para o problema específico.

Transfer Learning

- Rede mais usada é a ImageNet: 14 milhões de imagens e mais de mil classes.
- Camadas iniciais detectam padrões de baixo nível (como curvas e bordas), que são universais.
- Se a base analisada é muito diferente da ImageNet pode-se usar menos camadas pré-treinadas e mais para o problema específico.

ImageNet



flamingo



cock



ruffed grouse

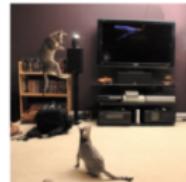


quail



partridge

...



Egyptian cat



Persian cat



Siamese cat

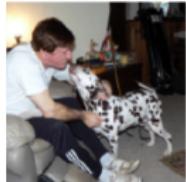


tabby



lynx

...



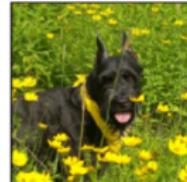
dalmatian



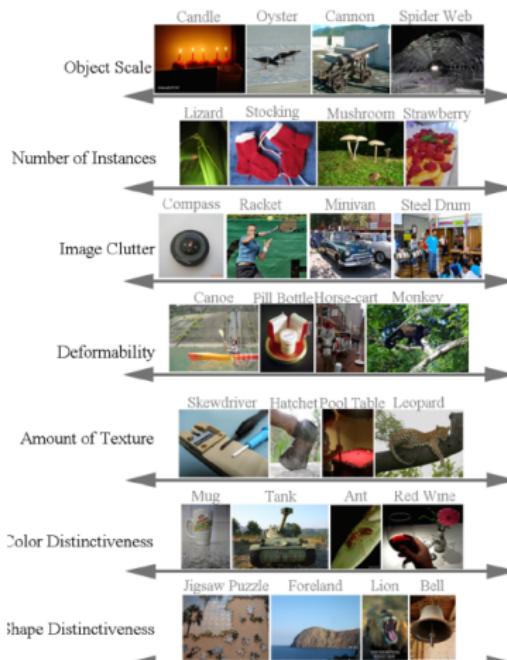
keeshond



miniature schnauzer standard schnauzer giant schnauzer



ImageNet



ImageNet

MNIST
60 MB



ImageNet
50 GB



Data Augmentation

- *Deep learning* precisa de muito dado para treinar.
- Aumentar base artificialmente.
- Rotação, translação, espelhamento, recortes aleatórios, conversão para tons de cinza, ruído, etc.

Data Augmentation

- Deep learning precisa de muito dado para treinar.
- Aumentar base artificialmente.
- Rotação, translação, espelhamento, recortes aleatórios, conversão para tons de cinza, ruído, etc.

Data Augmentation

- *Deep learning* precisa de muito dado para treinar.
- Aumentar base artificialmente.
- Rotação, translação, espelhamento, recortes aleatórios, conversão para tons de cinza, ruído, etc.

Outline

1 Na Prática

2 Histórico

3 Futuro

Histórico

- Trabalho pioneiro de Yann LeCun et al. em 1998: “*Gradient-based learning applied to document recognition*” .
- Rede LeNet (este trabalho iniciou-se em 1988).
- Reconhecimento de dígitos, CEP, etc.
- “Olimpíada” anual da Visão Computacional: ILSVRC (*ImageNet Large-Scale Visual Recognition Challenge*).
- Equipes do mundo todo se enfrentando em tarefas de classificação, localização, detecção, etc.

Histórico

- Trabalho pioneiro de Yann LeCun et al. em 1998: “*Gradient-based learning applied to document recognition*”.
- Rede LeNet (este trabalho iniciou-se em 1988).
- Reconhecimento de dígitos, CEP, etc.
- “Olimpíada” anual da Visão Computacional: ILSVRC (*ImageNet Large-Scale Visual Recognition Challenge*).
- Equipes do mundo todo se enfrentando em tarefas de classificação, localização, detecção, etc.

Histórico

- Trabalho pioneiro de Yann LeCun et al. em 1998: “*Gradient-based learning applied to document recognition*”.
- Rede LeNet (este trabalho iniciou-se em 1988).
- Reconhecimento de dígitos, CEP, etc.
- “Olimpíada” anual da Visão Computacional: ILSVRC (*ImageNet Large-Scale Visual Recognition Challenge*).
- Equipes do mundo todo se enfrentando em tarefas de classificação, localização, detecção, etc.

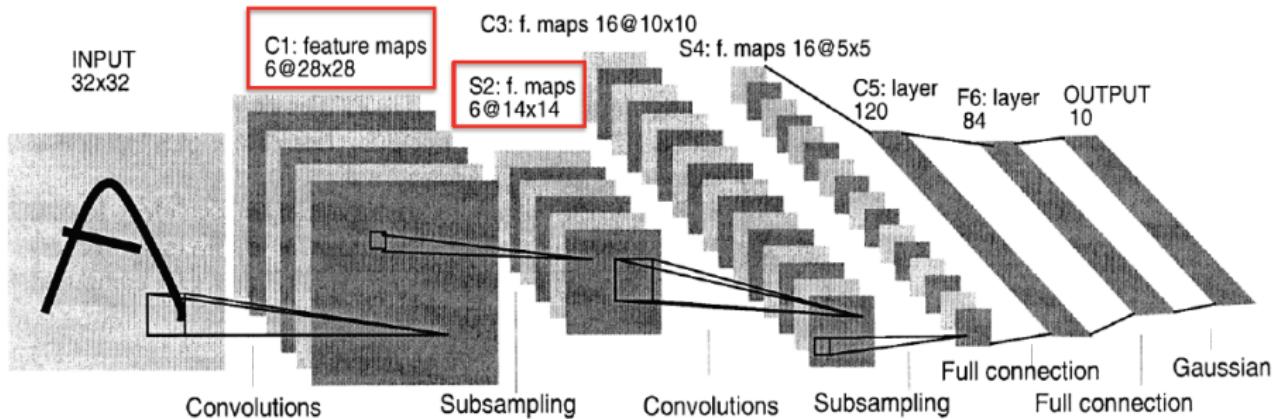
Histórico

- Trabalho pioneiro de Yann LeCun et al. em 1998: “*Gradient-based learning applied to document recognition*”.
- Rede LeNet (este trabalho iniciou-se em 1988).
- Reconhecimento de dígitos, CEP, etc.
- “Olimpíada” anual da Visão Computacional: ILSVRC (*ImageNet Large-Scale Visual Recognition Challenge*).
- Equipes do mundo todo se enfrentando em tarefas de classificação, localização, detecção, etc.

Histórico

- Trabalho pioneiro de Yann LeCun et al. em 1998: “*Gradient-based learning applied to document recognition*”.
- Rede LeNet (este trabalho iniciou-se em 1988).
- Reconhecimento de dígitos, CEP, etc.
- “Olimpíada” anual da Visão Computacional: ILSVRC (*ImageNet Large-Scale Visual Recognition Challenge*).
- Equipes do mundo todo se enfrentando em tarefas de classificação, localização, detecção, etc.

Histórico



Histórico

- 2012 é um ano marcante: CNN aparece pela primeira vez no ILSVRC com um erro “top 5” de 15.4% na ImageNet (o 2º colocado errou 26.2%!!!).
- Rede AlexNet (Alex Krizhevsky, Ilya Sutskever, Geoffrey Hinton).
- Arquitetura simples para os dias de hoje.
- Treinamento da ImageNet sobre 15 milhões de imagens e 22 mil classes.
- Não-linearidade usando ReLU, *data augmentation*, *dropout*, gradiente estocástico, momento e *weight decay*.
- Treinada em uma GTX 580 durante 5 a 6 dias.

Histórico

- 2012 é um ano marcante: CNN aparece pela primeira vez no ILSVRC com um erro “top 5” de 15.4% na ImageNet (o 2º colocado errou 26.2%!!!).
- Rede AlexNet (Alex Krizhevsky, Ilya Sutskever, Geoffrey Hinton).
 - Arquitetura simples para os dias de hoje.
 - Treinamento da ImageNet sobre 15 milhões de imagens e 22 mil classes.
 - Não-linearidade usando ReLU, *data augmentation*, *dropout*, gradiente estocástico, momento e *weight decay*.
 - Treinada em uma GTX 580 durante 5 a 6 dias.

Histórico

- 2012 é um ano marcante: CNN aparece pela primeira vez no ILSVRC com um erro “top 5” de 15.4% na ImageNet (o 2º colocado errou 26.2%!!!).
- Rede AlexNet (Alex Krizhevsky, Ilya Sutskever, Geoffrey Hinton).
- Arquitetura simples para os dias de hoje.
- Treinamento da ImageNet sobre 15 milhões de imagens e 22 mil classes.
- Não-linearidade usando ReLU, *data augmentation*, *dropout*, gradiente estocástico, momento e *weight decay*.
- Treinada em uma GTX 580 durante 5 a 6 dias.

Histórico

- 2012 é um ano marcante: CNN aparece pela primeira vez no ILSVRC com um erro “top 5” de 15.4% na ImageNet (o 2º colocado errou 26.2%!!!).
- Rede AlexNet (Alex Krizhevsky, Ilya Sutskever, Geoffrey Hinton).
- Arquitetura simples para os dias de hoje.
- Treinamento da ImageNet sobre 15 milhões de imagens e 22 mil classes.
- Não-linearidade usando ReLU, *data augmentation*, *dropout*, gradiente estocástico, momento e *weight decay*.
- Treinada em uma GTX 580 durante 5 a 6 dias.

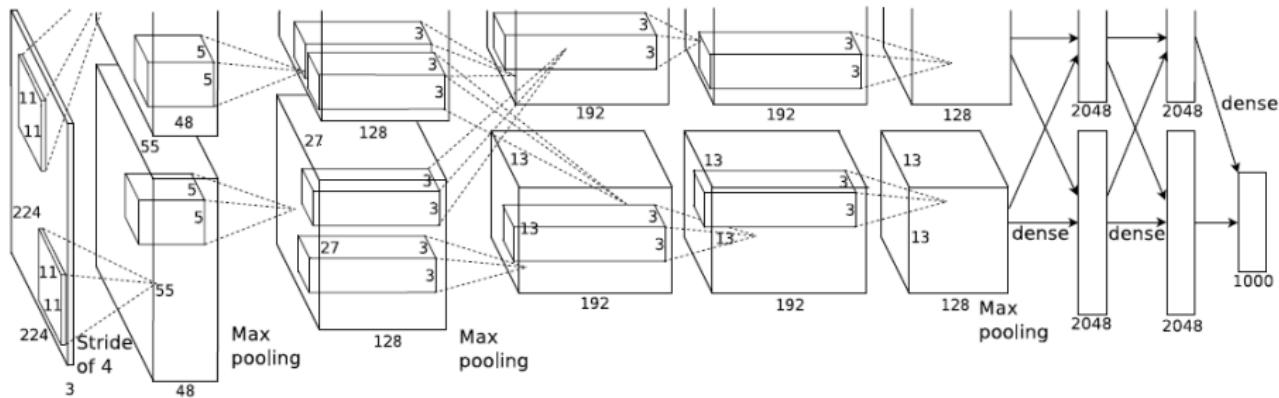
Histórico

- 2012 é um ano marcante: CNN aparece pela primeira vez no ILSVRC com um erro “top 5” de 15.4% na ImageNet (o 2º colocado errou 26.2%!!!).
- Rede AlexNet (Alex Krizhevsky, Ilya Sutskever, Geoffrey Hinton).
- Arquitetura simples para os dias de hoje.
- Treinamento da ImageNet sobre 15 milhões de imagens e 22 mil classes.
- Não-linearidade usando ReLU, *data augmentation*, *dropout*, gradiente estocástico, momento e *weight decay*.
- Treinada em uma GTX 580 durante 5 a 6 dias.

Histórico

- 2012 é um ano marcante: CNN aparece pela primeira vez no ILSVRC com um erro “top 5” de 15.4% na ImageNet (o 2º colocado errou 26.2%!!!).
- Rede AlexNet (Alex Krizhevsky, Ilya Sutskever, Geoffrey Hinton).
- Arquitetura simples para os dias de hoje.
- Treinamento da ImageNet sobre 15 milhões de imagens e 22 mil classes.
- Não-linearidade usando ReLU, *data augmentation*, *dropout*, gradiente estocástico, momento e *weight decay*.
- Treinada em uma GTX 580 durante 5 a 6 dias.

Histórico



Histórico

- **ILSVRC 2013:** Vários modelos de CNNs são apresentados naquele ano.
- Vencedor é a ZF Net (Matthew Zeiler, Rob Fergus) com 11.2% de erro, treinando com “apenas” 1.3 milhões de imagens.
- Mudanças incrementais sobre a AlexNet.
- Maior contribuição foi na compreensão intuitiva do funcionamento da rede.
- Criaram o conceito de DeConvNet que “inverte” a convolução e permite que se localize a região da imagem original que ativa determinado filtro.

Histórico

- **ILSVRC 2013:** Vários modelos de CNNs são apresentados naquele ano.
- Vencedor é a ZF Net (Matthew Zeiler, Rob Fergus) com 11.2% de erro, treinando com “apenas” 1.3 milhões de imagens.
- Mudanças incrementais sobre a AlexNet.
- Maior contribuição foi na compreensão intuitiva do funcionamento da rede.
- Criaram o conceito de DeConvNet que “inverte” a convolução e permite que se localize a região da imagem original que ativa determinado filtro.

Histórico

- **ILSVRC 2013:** Vários modelos de CNNs são apresentados naquele ano.
- Vencedor é a ZF Net (Matthew Zeiler, Rob Fergus) com 11.2% de erro, treinando com “apenas” 1.3 milhões de imagens.
- Mudanças incrementais sobre a AlexNet.
- Maior contribuição foi na compreensão intuitiva do funcionamento da rede.
- Criaram o conceito de DeConvNet que “inverte” a convolução e permite que se localize a região da imagem original que ativa determinado filtro.

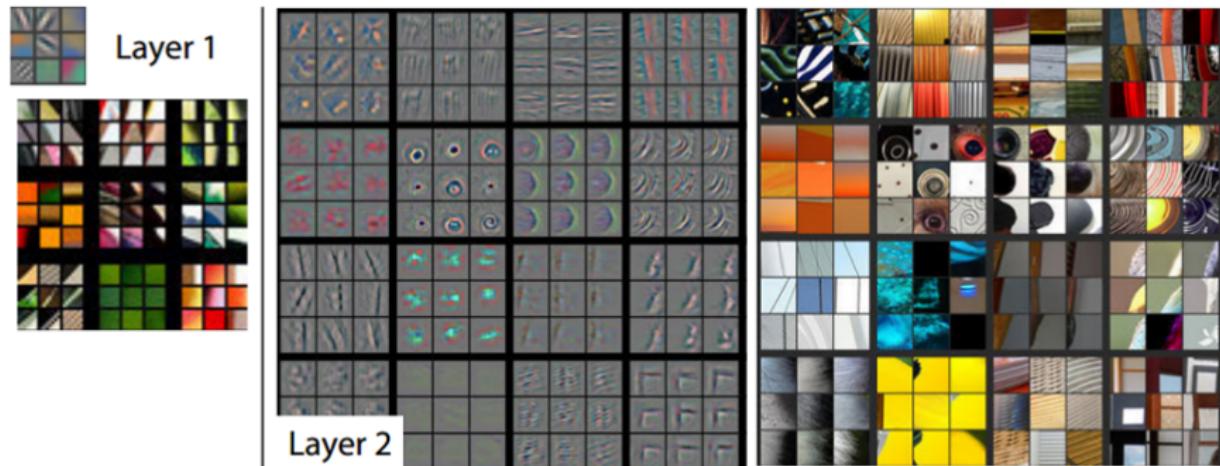
Histórico

- **ILSVRC 2013:** Vários modelos de CNNs são apresentados naquele ano.
- Vencedor é a ZF Net (Matthew Zeiler, Rob Fergus) com 11.2% de erro, treinando com “apenas” 1.3 milhões de imagens.
- Mudanças incrementais sobre a AlexNet.
- Maior contribuição foi na compreensão intuitiva do funcionamento da rede.
- Criaram o conceito de DeConvNet que “inverte” a convolução e permite que se localize a região da imagem original que ativa determinado filtro.

Histórico

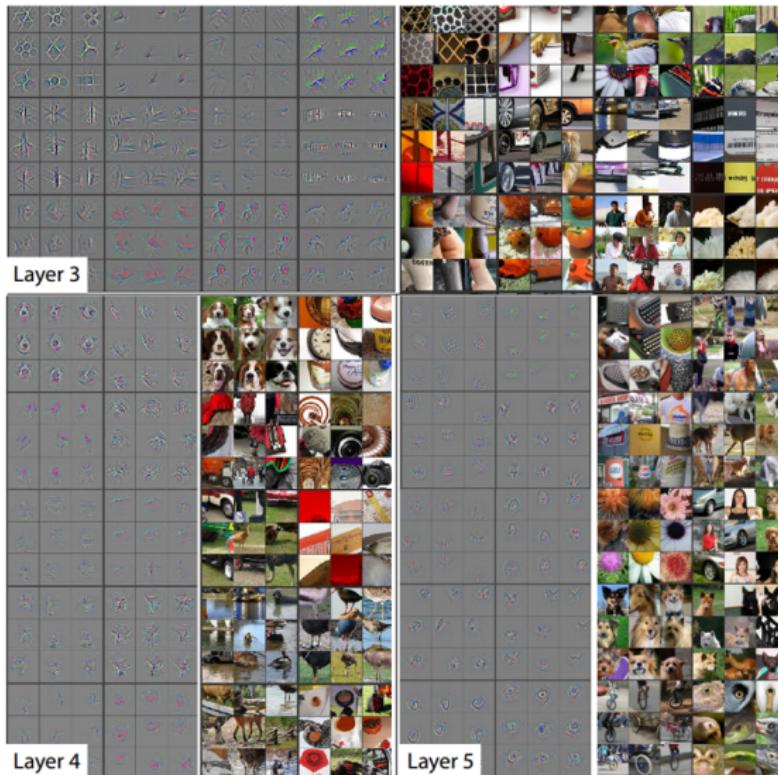
- **ILSVRC 2013:** Vários modelos de CNNs são apresentados naquele ano.
- Vencedor é a ZF Net (Matthew Zeiler, Rob Fergus) com 11.2% de erro, treinando com “apenas” 1.3 milhões de imagens.
- Mudanças incrementais sobre a AlexNet.
- Maior contribuição foi na compreensão intuitiva do funcionamento da rede.
- Criaram o conceito de DeConvNet que “inverte” a convolução e permite que se localize a região da imagem original que ativa determinado filtro.

Histórico



Visualizations of Layer 1 and 2. Each layer illustrates 2 pictures, one which shows the filters themselves and one that shows what part of the image are most strongly activated by the given filter. For example, in the space labeled Layer 2, we have representations of the 16 different filters (on the left)

Histórico



Visualizations of Layers 3, 4, and 5

Histórico

- **VGG Net** (2014): Karen Simonyan e Andrew Zisserman (Oxford).
 - Erro de 7.3% treinando com 4 GPUs Titan Black por 2-3 semanas.
 - Uso de filtros 3×3 menores que os usado até então (AlexNet usa 11×11).
 - Maior número de camadas: 19.
 - “Keep it deep, keep it simple!”

Histórico

- **VGG Net** (2014): Karen Simonyan e Andrew Zisserman (Oxford).
- Erro de 7.3% treinando com 4 GPUs Titan Black por 2-3 semanas.
- Uso de filtros 3×3 menores que os usado até então (AlexNet usa 11×11).
- Maior número de camadas: 19.
- “Keep it deep, keep it simple!”

Histórico

- **VGG Net** (2014): Karen Simonyan e Andrew Zisserman (Oxford).
- Erro de 7.3% treinando com 4 GPUs Titan Black por 2-3 semanas.
- Uso de filtros 3×3 menores que os usado até então (AlexNet usa 11×11).
- Maior número de camadas: 19.
- “Keep it deep, keep it simple!”

Histórico

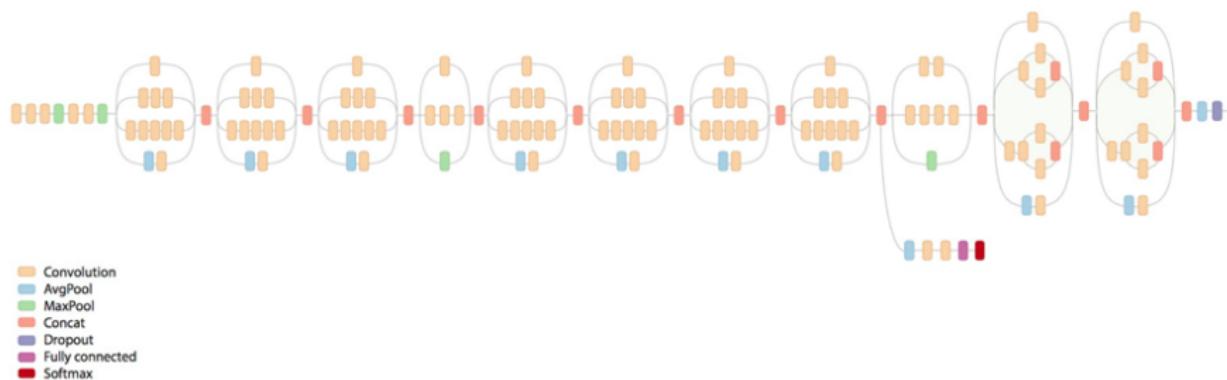
- **VGG Net** (2014): Karen Simonyan e Andrew Zisserman (Oxford).
- Erro de 7.3% treinando com 4 GPUs Titan Black por 2-3 semanas.
- Uso de filtros 3×3 menores que os usado até então (AlexNet usa 11×11).
- Maior número de camadas: 19.
- “Keep it deep, keep it simple!”

Histórico

- **VGG Net** (2014): Karen Simonyan e Andrew Zisserman (Oxford).
- Erro de 7.3% treinando com 4 GPUs Titan Black por 2-3 semanas.
- Uso de filtros 3×3 menores que os usado até então (AlexNet usa 11×11).
- Maior número de camadas: 19.
- “Keep it deep, keep it simple!”

Histórico

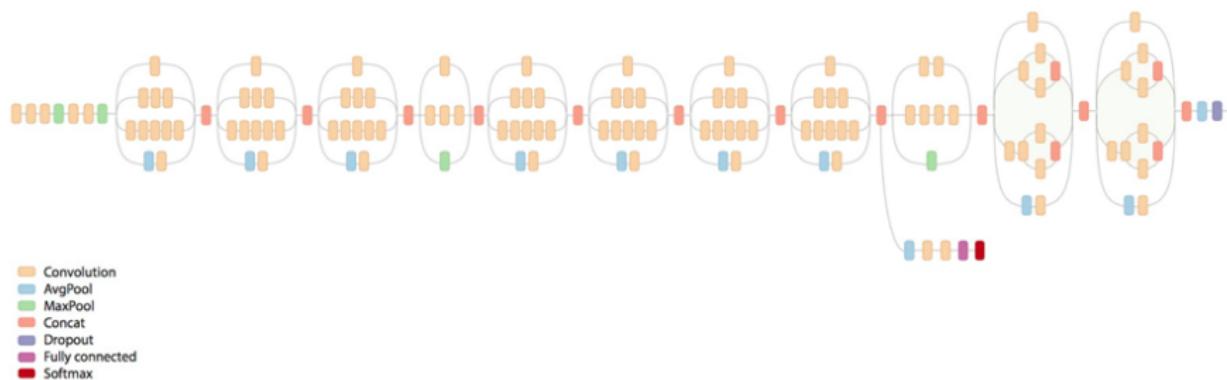
- **ILSVRC 2014:** GoogLeNet - erro top 5 de 6.7%.
- Mudança de paradigma: rede não precisa ser sequencial.



Another view of GoogleNet's architecture.

Histórico

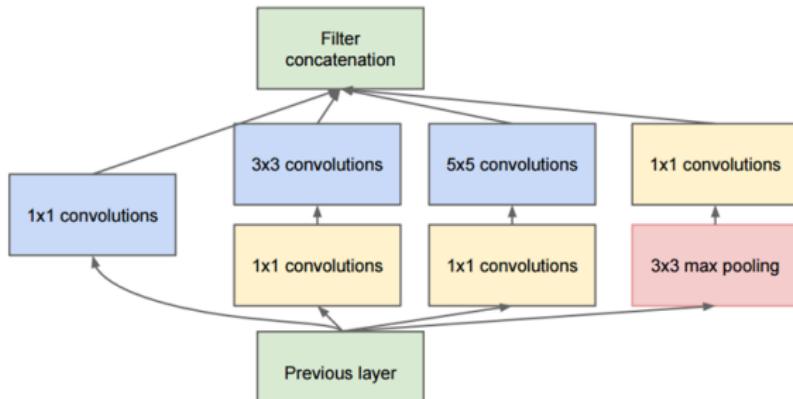
- **ILSVRC 2014:** GoogLeNet - erro top 5 de 6.7%.
- Mudança de paradigma: rede não precisa ser sequencial.



Another view of GoogleNet's architecture.

Histórico

Inception module



Full Inception module

Histórico

- Convoluçãoções e *pooling* em paralelo.
- Convoluçãoções 1×1 reduzem a dimensionalidade (por exemplo se a entrada é $100 \times 100 \times 100$) a aplicação de 10 filtros reduz para $100 \times 100 \times 10$.
- Após cada convolução, uma ReLU.
- Simplicidade deixada de lado: 19 camadas.
- “Algumas” GPUs treinando por uma semana.

Histórico

- Convoluçãoes e *pooling* em paralelo.
- Convoluçãoes 1×1 reduzem a dimensionalidade (por exemplo se a entrada é $100 \times 100 \times 100$) a aplicação de 10 filtros reduz para $100 \times 100 \times 10$.
- Após cada convolução, uma ReLU.
- Simplicidade deixada de lado: 19 camadas.
- “Algumas” GPUs treinando por uma semana.

Histórico

- Convoluçãoes e *pooling* em paralelo.
- Convoluçãoes 1×1 reduzem a dimensionalidade (por exemplo se a entrada é $100 \times 100 \times 100$) a aplicação de 10 filtros reduz para $100 \times 100 \times 10$.
- Após cada convolução, uma ReLU.
- Simplicidade deixada de lado: 19 camadas.
- “Algumas” GPUs treinando por uma semana.

Histórico

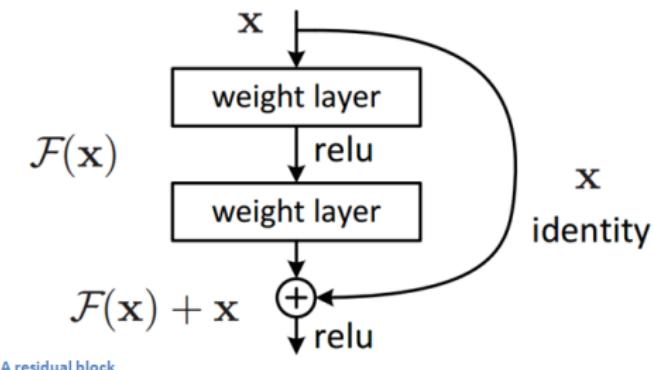
- Convoluçãoes e *pooling* em paralelo.
- Convoluçãoes 1×1 reduzem a dimensionalidade (por exemplo se a entrada é $100 \times 100 \times 100$) a aplicação de 10 filtros reduz para $100 \times 100 \times 10$.
- Após cada convolução, uma ReLU.
- Simplicidade deixada de lado: 19 camadas.
- “Algumas” GPUs treinando por uma semana.

Histórico

- Convoluçãoes e *pooling* em paralelo.
- Convoluçãoes 1×1 reduzem a dimensionalidade (por exemplo se a entrada é $100 \times 100 \times 100$) a aplicação de 10 filtros reduz para $100 \times 100 \times 10$.
- Após cada convolução, uma ReLU.
- Simplicidade deixada de lado: 19 camadas.
- “Algumas” GPUs treinando por uma semana.

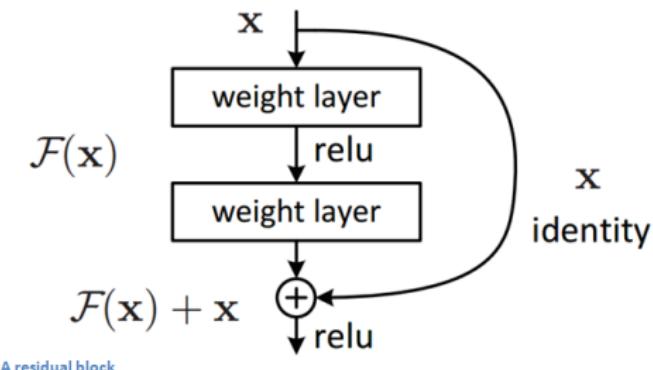
Histórico

- **ILSVRC 2015:** ResNet (Microsoft Research Asia) - erro de 3.6% com 8 GPUs por 2-3 semanas.
- Note que seres humanos costumam errar entre 5 e 10%.
- 152 camadas! (“Ultra-deep”)
- Bloco residual - facilita otimização (gradiente distribui sobre soma).



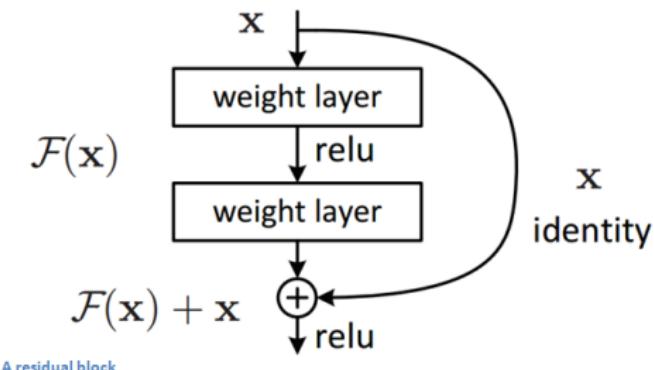
Histórico

- **ILSVRC 2015:** ResNet (Microsoft Research Asia) - erro de 3.6% com 8 GPUs por 2-3 semanas.
- Note que seres humanos costumam errar entre 5 e 10%.
- 152 camadas! (“Ultra-deep”)
- Bloco residual - facilita otimização (gradiente distribui sobre soma).



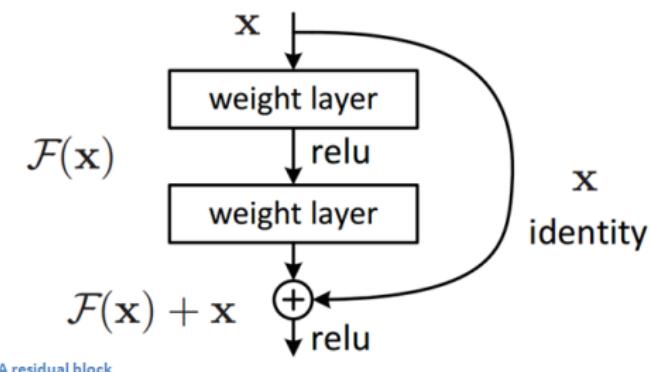
Histórico

- **ILSVRC 2015:** ResNet (Microsoft Research Asia) - erro de 3.6% com 8 GPUs por 2-3 semanas.
- Note que seres humanos costumam errar entre 5 e 10%.
- 152 camadas! (“Ultra-deep”)
- Bloco residual - facilita otimização (gradiente distribui sobre soma).



Histórico

- **ILSVRC 2015:** ResNet (Microsoft Research Asia) - erro de 3.6% com 8 GPUs por 2-3 semanas.
- Note que seres humanos costumam errar entre 5 e 10%.
- 152 camadas! (“Ultra-deep”)
- Bloco residual - facilita otimização (gradiente distribui sobre soma).



Histórico

- **DenseNet** (2016): Huang et al.
 - Redes convolucionais totalmente conectadas.
 - Atenua gradiente muito pequeno, diminui número de parâmetros, reúso de atributos, etc.
 - Erro top 5 de 6.12% na ImageNet.

Histórico

- **DenseNet** (2016): Huang et al.
- Redes convolucionais totalmente conectadas.
- Atenua gradiente muito pequeno, diminui número de parâmetros, reúso de atributos, etc.
- Erro top 5 de 6.12% na ImageNet.

Histórico

- **DenseNet** (2016): Huang et al.
- Redes convolucionais totalmente conectadas.
- Atenua gradiente muito pequeno, diminui número de parâmetros, reúso de atributos, etc.
- Erro top 5 de 6.12% na ImageNet.

Histórico

- **DenseNet** (2016): Huang et al.
- Redes convolucionais totalmente conectadas.
- Atenua gradiente muito pequeno, diminui número de parâmetros, reúso de atributos, etc.
- Erro top 5 de 6.12% na ImageNet.

Outline

1 Na Prática

2 Histórico

3 Futuro

Casos de Sucesso

- Investimento pesado do Google (*Deep Mind*). China investindo 150 bilhões de dólares em IA.
- Leitura labial (superando especialista da BBC).
- Reconhecimento de caracteres em nomes de ruas e lojas (*Street View*).
- Robôs, carro autônomo, realidade virtual, smartphones, etc.

Casos de Sucesso

- Investimento pesado do Google (*Deep Mind*). China investindo 150 bilhões de dólares em IA.
- Leitura labial (superando especialista da BBC).
- Reconhecimento de caracteres em nomes de ruas e lojas (*Street View*).
- Robôs, carro autônomo, realidade virtual, smartphones, etc.

Casos de Sucesso

- Investimento pesado do Google (*Deep Mind*). China investindo 150 bilhões de dólares em IA.
- Leitura labial (superando especialista da BBC).
- Reconhecimento de caracteres em nomes de ruas e lojas (*Street View*).
- Robôs, carro autônomo, realidade virtual, smartphones, etc.

Casos de Sucesso

- Investimento pesado do Google (*Deep Mind*). China investindo 150 bilhões de dólares em IA.
- Leitura labial (superando especialista da BBC).
- Reconhecimento de caracteres em nomes de ruas e lojas (*Street View*).
- Robôs, carro autônomo, realidade virtual, smartphones, etc.

Casos de Sucesso - Área Médica

- Diagnóstico preciso e rápido de doenças cardiovasculares por MRI (não invasivo).
- Interpretação de imagens médicas (tomografia, raio-X) usando-se uma base mundial de imagens associadas a termos típicos de diagnósticos.
- Detecção prematura de retinopatia diabética (uma das maiores causas de cegueira).
- Detecção de tumores em geral, p.ex. melanoma (IBM).
- Quantificação não invasiva da evolução de um tumor / redução do grupo de teste.
- Classificação de lesões e tumores.

Casos de Sucesso - Área Médica

- Diagnóstico preciso e rápido de doenças cardiovasculares por MRI (não invasivo).
- Interpretação de imagens médicas (tomografia, raio-X) usando-se uma base mundial de imagens associadas a termos típicos de diagnósticos.
- Detecção prematura de retinopatia diabética (uma das maiores causas de cegueira).
- Detecção de tumores em geral, p.ex. melanoma (IBM).
- Quantificação não invasiva da evolução de um tumor / redução do grupo de teste.
- Classificação de lesões e tumores.

Casos de Sucesso - Área Médica

- Diagnóstico preciso e rápido de doenças cardiovasculares por MRI (não invasivo).
- Interpretação de imagens médicas (tomografia, raio-X) usando-se uma base mundial de imagens associadas a termos típicos de diagnósticos.
- Detecção prematura de retinopatia diabética (uma das maiores causas de cegueira).
- Detecção de tumores em geral, p.ex. melanoma (IBM).
- Quantificação não invasiva da evolução de um tumor / redução do grupo de teste.
- Classificação de lesões e tumores.

Casos de Sucesso - Área Médica

- Diagnóstico preciso e rápido de doenças cardiovasculares por MRI (não invasivo).
- Interpretação de imagens médicas (tomografia, raio-X) usando-se uma base mundial de imagens associadas a termos típicos de diagnósticos.
- Detecção prematura de retinopatia diabética (uma das maiores causas de cegueira).
- Detecção de tumores em geral, p.ex. melanoma (IBM).
- Quantificação não invasiva da evolução de um tumor / redução do grupo de teste.
- Classificação de lesões e tumores.

Casos de Sucesso - Área Médica

- Diagnóstico preciso e rápido de doenças cardiovasculares por MRI (não invasivo).
- Interpretação de imagens médicas (tomografia, raio-X) usando-se uma base mundial de imagens associadas a termos típicos de diagnósticos.
- Detecção prematura de retinopatia diabética (uma das maiores causas de cegueira).
- Detecção de tumores em geral, p.ex. melanoma (IBM).
- Quantificação não invasiva da evolução de um tumor / redução do grupo de teste.
- Classificação de lesões e tumores.

Casos de Sucesso - Área Médica

- Diagnóstico preciso e rápido de doenças cardiovasculares por MRI (não invasivo).
- Interpretação de imagens médicas (tomografia, raio-X) usando-se uma base mundial de imagens associadas a termos típicos de diagnósticos.
- Detecção prematura de retinopatia diabética (uma das maiores causas de cegueira).
- Detecção de tumores em geral, p.ex. melanoma (IBM).
- Quantificação não invasiva da evolução de um tumor / redução do grupo de teste.
- Classificação de lesões e tumores.